

SEMAINE 7

Exercice 45.

- (i) On a $\hat{\lambda}_n = n^{-1} \sum_{i=1}^n X_i$. Par la loi faible des grands nombres, $\hat{\lambda}_n \xrightarrow{p} \mathbb{E}X_1 = \lambda$ et donc $\hat{\lambda}_n$ est consistant. Puisque $\mathbb{E}[\hat{\lambda}_n] = \lambda$, $\hat{\lambda}_n$ est en plus non-biaisé.
- (ii) L'estimateur $\tilde{\lambda}_n = \hat{\lambda}_n + \frac{1}{n}$ est un exemple d'estimateur biaisé mais consistant. L'estimateur $\frac{n+1}{n} \hat{\lambda}_n$ en est un autre.

Exercice 46.

- (i) En dérivant la fonction de log vraisemblance (par rapport à λ)

$$\ell_n(\lambda) = \log(\lambda^n e^{-\lambda \sum_{i=1}^n x_i}) = n \log \lambda - \lambda \sum_{i=1}^n x_i,$$

et en la posant égale à zéro, nous obtenons

$$\hat{\lambda}_n = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{X}_n}.$$

La fonction ℓ_n étant concave, il s'agit bien d'un maximum.

- (ii) Nous pouvons en effet utiliser la proposition 3.17, puisque $\lambda \mapsto \theta = \frac{1}{\lambda}$ sur $]0, \infty[$ est une fonction bijective de λ . Donc $\hat{\theta}_n^{\text{MV}} = 1/\hat{\lambda}_n = \bar{X}_n$. C'est un estimateur non biaisé de θ .
- (iii) Nous savons que

$$\mathbb{E}_\lambda(\hat{\lambda}_n) = \frac{n}{n-1} \lambda \quad \implies \quad \beta(\lambda) = \mathbb{E}_\lambda \hat{\lambda}_n - \lambda = \frac{\lambda}{n-1}.$$

L'information de Fisher $I(\lambda)$ est

$$\begin{aligned} I(\lambda) &= \mathbb{E} \left[\left\{ \frac{\partial}{\partial \lambda} \log(\lambda \exp(-\lambda X_1)) \right\}^2 \right] \\ &= \mathbb{E} \left[\left\{ \frac{1}{\lambda} - X_1 \right\}^2 \right] \\ &= \mathbb{E} \left[\frac{1}{\lambda^2} - \frac{2}{\lambda} X_1 + X_1^2 \right] = \frac{1}{\lambda^2}, \end{aligned}$$

car $X_1 \sim \text{Exp}(\lambda)$ dont l'espérance est $1/\lambda$ et la variance $1/\lambda^2$. La borne de Cramér–Rao est donc

$$\frac{(\beta'(\lambda) + 1)^2}{nI(\lambda)} = \frac{(1 + 1/(n-1))^2}{n/\lambda^2} = \frac{n^2 \lambda^2}{n(n-1)^2} = \frac{n \lambda^2}{(n-1)^2}.$$

(Au fait, la borne de Cramér–Rao correspondante à aT est a^2 fois la borne de Cramér–Rao correspondante à T , si $a \in \mathbb{R}$; on aurait donc pu utiliser le fait que la borne de Cramér–Rao pour $\hat{\lambda}_n^{\text{NB}} = (n-1)\hat{\lambda}_n/n$ est λ^2/n .)

Or

$$\text{Var}_\lambda(\hat{\lambda}_n) = \frac{n^2}{(n-1)^2(n-2)} \lambda^2 = \frac{n \lambda^2}{(n-1)^2} \frac{n}{n-2} > \frac{n \lambda^2}{(n-1)^2}.$$

L'estimateur $\hat{\lambda}_n$ n'atteint donc (tout juste) pas la borne de Cramér-Rao.

Quant à θ , l'information de Fisher $I(\theta)$ est

$$\begin{aligned} I(\theta) &= \mathbb{E} \left[\left\{ \frac{\partial}{\partial \theta} \log \left(\frac{1}{\theta} \exp \left(-\frac{1}{\theta} X_1 \right) \right) \right\}^2 \right] \\ &= \mathbb{E} \left[\left\{ \frac{X_1}{\theta^2} - \frac{1}{\theta} \right\}^2 \right] \\ &= \frac{1}{\theta^2} \mathbb{E} \left[\frac{X_1^2}{\theta^2} - \frac{2}{\theta} X_1 + 1 \right] = \frac{1}{\theta^2}. \end{aligned}$$

La borne de Cramér-Rao est donc $\theta^2/n = \text{Var}_\theta(\hat{\theta}_n^{\text{MV}})$, donc $\hat{\theta}_n^{\text{MV}}$ atteint la borne de Cramér-Rao.

Exercice 47. L'espérance de la durée des conversations est $1/\lambda$. Lorsque les soupçons du monsieur sont justifiés, la fonction de répartition de la distribution qui génère l'échantillon t_1, \dots, t_n est

$$F_T(t) = \mathbb{P} \left[Y \leq t | Y > \frac{1}{\lambda} \right], \quad t \geq \frac{1}{\lambda},$$

où $Y \sim \text{Exp}(\lambda)$. Grâce à l'absence de mémoire de la distribution exponentielle (cf. exercice 6, série 1), on a pour $t \geq \lambda^{-1}$

$$F_T(t) = 1 - \mathbb{P} \left[Y > t | Y > \frac{1}{\lambda} \right] = 1 - \mathbb{P} \left[Y > t - \frac{1}{\lambda} \right] = 1 - e^{-\lambda(t-1/\lambda)} = 1 - e^{1-\lambda t}.$$

La densité de la variable aléatoire T est donc $f(t; \lambda) = \lambda e^{1-\lambda t} \mathbf{1}\{t \geq \lambda^{-1}\}$. La vraisemblance à partir d'un échantillon t_1, \dots, t_n s'écrit

$$\begin{aligned} L_n(\lambda; (t_i)) &= \prod_{i=1}^n f(t_i; \lambda) = \lambda^n e^{n-\lambda \sum_{i=1}^n t_i} \prod_{i=1}^n \mathbf{1}\{t_i \geq 1/\lambda\} \\ &= \lambda^n e^{n-\lambda \sum_{i=1}^n t_i} \mathbf{1}\{\lambda \geq 1/t_{(1)}\}, \quad t_{(1)} = \min\{t_1, \dots, t_n\}, \end{aligned}$$

puisque $\prod_{i=1}^n \mathbf{1}\{t_i \geq 1/\lambda\} = 1$ si et seulement si $t_{(1)} \geq 1/\lambda$ si et seulement si $\lambda \geq 1/t_{(1)}$.

Afin de maximiser cette fonction, faisons comme si la fonction indicatrice n'était pas là et dérivons $\ell_n(\lambda; (t_i)) = n \log(\lambda) + n - n\lambda \bar{t}$:


$$\frac{\partial \ell_n}{\partial \lambda} = \frac{n}{\lambda} - n\bar{t}.$$

En posant cette dernière équation égale à zéro, nous obtenons :

$$\frac{\partial \ell_n}{\partial \lambda} = 0 \iff \hat{\lambda} = \frac{1}{\bar{t}}.$$

Malheureusement, puisque $\bar{t} > t_{(1)}$, $\frac{1}{\bar{t}} < \frac{1}{t_{(1)}}$; notre solution ne satisfait donc pas à la condition $\lambda \geq 1/t_{(1)}$ et la vraisemblance vaut zéro. Puisque ℓ_n (et donc L_n) est décroissante sur $[1/t_{(1)}, \infty[$, le maximum sera atteint au premier point où la vraisemblance ne s'annule pas (voir le graphique ci-dessous). L'estimateur est donc $\hat{\lambda}_n = 1/t_{(1)}$.

Remarque. Il se peut que $\bar{t} = t_{(1)}$, mais même dans ce cas l'estimateur sera $1/t_{(1)} = 1/\bar{t}$. Cette particularité n'arrive cependant qu'avec probabilité zéro, à moins que $n = 1$.



Exercice 48.

- (i) Puisque l'espérance d'une variable aléatoire χ_{n-1}^2 est $n-1$ et sa variance est $2(n-1)$, $\mathbb{E}[S_n^2] = \sigma^2$ et $EQM(S_n^2, \sigma^2) = \text{Var}[S_n^2] = 2\sigma^4/(n-1)$.
Puisque $\hat{\sigma}_n^2 = (n-1)S_n^2/n$, nous avons $\mathbb{E}[\hat{\sigma}_n^2] = (n-1)\sigma^2/n$ et $\text{Var}[\hat{\sigma}_n^2] = 2(n-1)\sigma^4/n^2$.
Ainsi

$$EQM(\hat{\sigma}_n^2, \sigma^2) = \left(\frac{n-1}{n}\sigma^2 - \sigma^2 \right)^2 + \frac{2(n-1)}{n^2}\sigma^4 = \frac{2n-1}{n^2}\sigma^4 < \frac{2}{n-1}\sigma^4,$$

puisque $\sigma^4 > 0$ et $(2n-1)/n^2 < 2/n < 2/(n-1)$. On remarque que même si $\hat{\sigma}_n^2$ est biaisé et S_n^2 ne l'est pas, ce dernier a une erreur quadratique moyenne plus élevée.

- (ii) Ici l'espérance est $a\sigma^2$ et la variance $2a^2\sigma^4/(n-1)$ de sorte que l'erreur quadratique moyenne vaille

$$(a\sigma^2 - \sigma^2)^2 + \frac{2a^2}{n-1}\sigma^4 = \sigma^4 \left((a-1)^2 + \frac{2a^2}{n-1} \right) = \frac{\sigma^4}{n-1} ((a^2 - 2a + 1)(n-1) + 2a^2).$$

C'est une parabole convexe en fonction de a dont l'unique minimum est la racine de l'équation

$$0 = 2a(n-1) + 4a - 2(n-1) = 2a(n+1) - 2(n-1) \implies a = \frac{n-1}{n+1}.$$

Ainsi le meilleur estimateur de cette forme est

$$\frac{n-1}{n+1}S_n^2 = \frac{1}{n+1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Exercice 49. L'estimateur de maximum de vraisemblance est $\hat{\theta}_n = X_{(n)}$ (cf. l'exemple 3.20, p. 77). On trouve pour $x \geq 0$,

$$\begin{aligned} \mathbb{P}(n(\theta - \hat{\theta}_n) \leq x) &= \mathbb{P}\left(X_{(n)} \geq \theta - \frac{x}{n}\right) = 1 - \mathbf{1}\{x \leq n\theta\} \left(1 - \frac{x}{\theta n}\right)^n \\ &\rightarrow 1 - \exp\left(-\frac{x}{\theta}\right), \quad n \rightarrow \infty. \end{aligned}$$

Ainsi $n(\theta - \hat{\theta}_n) \xrightarrow{d} \text{Exp}(1/\theta)$.

Exercice 50.

(i) Remarquons que

$$\begin{aligned}\ell_n(\theta) &= \log f(X_1, \dots, X_n; \theta) = \eta(\theta) \sum_{i=1}^n T(X_i) - nd(\theta) + \sum_{i=1}^n S(X_i); \\ \ell'_n(\theta) &= \eta'(\theta) \sum_{i=1}^n T(X_i) - nd'(\theta) = n(\eta'(\theta)\bar{T} - d'(\theta)); \\ \ell''_n(\theta) &= \eta''(\theta) \sum_{i=1}^n T(X_i) - nd''(\theta) = n(\eta''(\theta)\bar{T} - d''(\theta)).\end{aligned}$$

Par l'exercice 35, $\mathbb{E}[\ell'_n(\theta)] = n(\eta'(\theta)\mathbb{E}[\bar{T}] - d'(\theta)) = 0$ et

$$\begin{aligned}\mathbb{E}[(\ell'_n(\theta))^2] &= \text{Var}[\ell'_n(\theta)] = n^2(\eta'(\theta))^2 \text{Var}[\bar{T}] = n \frac{d''(\theta)\eta'(\theta) - d'(\theta)\eta''(\theta)}{\eta'(\theta)}; \\ \mathbb{E}[\ell''_n(\theta)] &= n(\eta''(\theta)\mathbb{E}[\bar{T}] - d''(\theta)) = n \left(\eta''(\theta) \frac{d'(\theta)}{\eta'(\theta)} - d''(\theta) \right) = n \frac{d'(\theta)\eta''(\theta) - d''(\theta)\eta'(\theta)}{\eta'(\theta)},\end{aligned}$$

tel que requis.

(ii) Soit $\ell_n(\theta; X_1, \dots, X_n) = \log f(X_1, \dots, X_n; \theta)$. Afin d'alléger la notation (souvent quelque peu fastidieuse en statistiques), nous allons simplement écrire f et ℓ_n . Lorsqu'on prend une dérivée, cela se fait toujours par rapport à θ . (En fait il n'a souvent pas de sens de dériver par rapport à x , par exemple lorsque l'espace \mathcal{X} est discret.) Avec cette notation, la question est : est-ce que $\mathbb{E}[\ell''_n] = -\mathbb{E}[(\ell'_n)^2]$?

Dérivons : $\ell'_n = f'/f$ et $\ell''_n = (f''f - f'f')/f^2$. Par conséquent, $\mathbb{E}[(\ell'_n)^2] = -\mathbb{E}[\ell''_n]$ si et seulement si

$$\begin{aligned}\int_{\mathcal{X}^n} \frac{(f')^2}{f} d\vec{x} &= \int_{\mathcal{X}^n} (\ell'_n)^2 f d\vec{x} = \mathbb{E}[(\ell'_n)^2] = -\mathbb{E}[\ell''_n] \\ &= -\int_{\mathcal{X}^n} \left(\frac{f''}{f} - \frac{(f')^2}{f^2} \right) f d\vec{x} = \int_{\mathcal{X}^n} \frac{(f')^2}{f} d\vec{x} - \int_{\mathcal{X}^n} f'' d\vec{x}.\end{aligned}$$

De manière équivalente, $0 = \int_{\mathcal{X}^n} f'' d\vec{x}$ ou bien :

$$\frac{\partial^2}{\partial \theta^2} \int_{\mathcal{X}^n} f(\vec{x}; \theta) d\vec{x} = \frac{\partial^2}{\partial \theta^2} 1 = 0 = \int_{\mathcal{X}^n} f'' d\vec{x} = \int_{\mathcal{X}^n} \frac{\partial^2}{\partial \theta^2} f d\vec{x},$$

car $f(\vec{x}; \theta)$ est une fonction de densité pour n'importe quel θ . En d'autres mots, $\mathbb{E}[\ell''_n(\theta)] = -\mathbb{E}[(\ell'_n(\theta))^2]$ est équivalent au fait de pouvoir interchanger la dérivée seconde et l'intégrale comme le font nos amis les physiciens.

Exercice 51. Il s'agit bien d'une famille exponentielle, où

$$\begin{aligned}\ell_1(\theta) &= \log \theta + (\theta - 1) \log X; \\ \ell'_1(\theta) &= \frac{1}{\theta} + \log X; \\ \ell''_1(\theta) &= -\frac{1}{\theta^2}.\end{aligned}$$

Or, $\mathbb{E}[\ell'_1(\theta)] = 0$, et par conséquent $\mathbb{E}[\log X] = -1/\theta$. De plus, d'après l'exercice 1,

$$\frac{1}{\theta^2} = -\mathbb{E}[\ell''_1(\theta)] = \mathbb{E}[(\ell'_1(\theta))^2] = \frac{1}{\theta^2} + \frac{2\mathbb{E}[\log X]}{\theta} + \mathbb{E}[(\log X)^2] = \frac{1}{\theta^2} - \frac{2}{\theta^2} + \mathbb{E}[(\log X)^2],$$

donc $\mathbb{E}[(\log X)^2] = 2\theta^{-2}$.

Exercice 52. La densité de X est $f_X(x) = \lambda e^{-\lambda x} \mathbf{1}\{x \geq 0\}$ et grâce au corollaire 1.31 (p. 27) la densité de aX est $a^{-1}f_X(x/a) = (\lambda/a)e^{-(\lambda/a)x} \mathbf{1}\{x \geq 0\}$. Par miracle, il s'agit de la densité d'une variable aléatoire exponentielle de paramètre λ/a .

Exercice 53. L'estimateur de maximum de vraisemblance est $\hat{\lambda}_n = 1/t_{(1)}$ (cf. exercice 47). Or $t_{(1)} - 1/\lambda = \tilde{t}_{(1)} \sim \text{Exp}(n\lambda)$, où $\tilde{t} = t - 1/\lambda \sim \text{Exp}(\lambda)$ (cf. exercice 50).

Solution « intelligente ». Par l'exercice 52, $n(t_{(1)} - 1/\lambda) \sim \text{Exp}(\lambda)$. Appliquons la méthode delta avec $g(t) = -1/t$ et encore une fois l'exercice 3 pour conclure

$$n(\lambda - \hat{\lambda}_n) = n(\lambda - 1/t_{(1)}) = n(g(t_{(1)}) - g(1/\lambda)) \xrightarrow{d} \text{Exp}(\lambda)\lambda^2 \sim \text{Exp}(1/\lambda).$$

Solution « brute-force ». On peut calculer la distribution exacte de $a_n(\lambda - \hat{\lambda}_n)$, puisque c'est une fonction de $t_{(1)} - 1/\lambda$ dont on connaît la distribution : soit $x \geq 0$.

$$\begin{aligned} \mathbb{P}\left(a_n(\lambda - \hat{\lambda}_n) \leq x\right) &= \mathbb{P}\left(\hat{\lambda}_n \geq \lambda - \frac{x}{a_n}\right) \\ &= \mathbb{P}\left(t_{(1)} \leq \frac{a_n}{a_n\lambda - x}\right) \\ &= \mathbb{P}\left(t_{(1)} - \frac{1}{\lambda} \leq \frac{x}{\lambda(a_n\lambda - x)}\right) \\ &= 1 - \exp\left(\frac{-nx}{a_n\lambda - x}\right), \quad \text{ou 1 si } x \geq a_n\lambda. \end{aligned}$$

On aimerait que la limite de cette probabilité soit une fonction qui dépend de x . Si $a_n/n \rightarrow 0$ l'exponentielle converge vers 0 et donc la probabilité converge vers 1, et ce, quelque soit la valeur de x . Il faut donc que $a_n \geq O(n)$ et en particulier $a_n \rightarrow \infty$, ce qui implique que pour x fixé, $x < a_n\lambda$ pour n suffisamment grand. On a

$$\lim_{n \rightarrow \infty} 1 - \exp\left(\frac{-nx}{a_n\lambda - x}\right) = 1 - \exp\left(\lim_{n \rightarrow \infty} \frac{-nx}{a_n\lambda - x}\right) = 1 - \exp\left(\frac{-x}{\lambda} \lim_{n \rightarrow \infty} \frac{n}{a_n}\right),$$

car $a_n \rightarrow \infty$ donc λx devient négligeable lorsque $n \rightarrow \infty$. Si $a_n/n \rightarrow \infty$ la limite est 0 qui ne dépend pas de x . Il faut donc que $\lim_{n \rightarrow \infty} a_n/n \in]0, \infty[$, et on peut choisir par exemple $a_n = n$.

Remarque. Puisque $\lambda \geq \hat{\lambda}_n$, nous ne pouvons pas nous attendre à ce que la distribution limite de $a_n(\lambda - \hat{\lambda}_n)$ soit normale ; en effet, n'importe quelle distribution limite est forcément non-négative ! De même pour $a_n(\theta - \hat{\theta}_n)$.

Exercice 54. (i). Etant donné l'image originale x_i , les y_i suivent la distribution du bruit, et donc $y_i \sim N(x_i, \sigma^2)$. La log-vraisemblance de $\{x_i\}$ est donc donnée par

$$\ell_n(x_i; y_i, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i)^2.$$

En posant les dérivées de la log-vraisemblance égales à zéro, nous obtenons

$$\hat{x}_i = y_i.$$

Alors, nous avons montré que si on a une seule observation y_i par pixel, la vraisemblance ne nous donne aucune d'information supplémentaire sur l'image.

(ii). Maintenant, les y_i sont indépendants et sont distribués comme

$$y_i \sim \mathcal{N}(a + bx_i, \sigma^2).$$

La log-vraisemblance de $\{a, b\}$ est donc

$$\ell_n(a, b; y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - a - bx_i)^2$$

avec les dérivées partielles

$$\begin{aligned} \frac{\partial \ell_n}{\partial a} &= -2 \sum_i \frac{(y_i - a - bx_i)}{\sigma^2} \\ \frac{\partial \ell_n}{\partial b} &= -2 \sum_i \frac{(y_i - a - bx_i)}{\sigma^2} x_i. \end{aligned}$$

En posant les dérivées de égales à zéro, nous obtenons

$$\begin{aligned} \frac{\partial \ell_n}{\partial a} = 0 &\Leftrightarrow \sum_i \frac{y_i}{\sigma^2} - \frac{na}{\sigma^2} - \frac{b}{\sigma^2} \sum_i x_i = 0 \\ \frac{\partial \ell_n}{\partial b} = 0 &\Leftrightarrow \sum_i \frac{x_i y_i}{\sigma^2} - a \sum_i \frac{x_i}{\sigma^2} - b \sum_i \frac{x_i^2}{\sigma^2} = 0. \end{aligned}$$

Soit $\bar{x} = n^{-1} \sum_{i=1}^n x_i$, et soient $\overline{x^2}$, \bar{y} et \overline{xy} définis de la même manière. On trouve finalement que

$$\begin{aligned} \hat{a} &= \frac{\overline{x^2 \bar{y}} - \bar{x} \cdot \overline{xy}}{\overline{x^2} - \bar{x}^2} \\ \hat{b} &= \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2} \end{aligned}$$

Finalement, observez que (\hat{a}, \hat{b}) minimisent la somme des carrés résiduels $\sum_i (y_i - a - bx_i)^2$, et donc nous les appelons aussi les *estimateurs des moindres carrés*.